



Universidade do Minho
Escola de Ciências

Sistemas Operativos (2º ano de Ciências da
Computação)
**Trabalho Prático – Serviço de Indexação e
Pesquisa de Documentos**
Grupo 16

Feito por:

- Alexandra Isabel de Sousa Calafate (A100060)
- André Filipe Barbosa de Sousa (A87999)
- João Nuno Rodrigues Fernandes (A87971)

Table of Contents

1. Introdução	3
2. Arquitetura do Sistema	3
2.1 Servidor (dserver)	5
2.2 Cliente (dclient)	6
3. Implementação das Funcionalidades.....	6
3.1. Meta-informação de Documentos:.....	6
3.2. Indexação de Documentos (dclient -a "título" "autores" "ano" "caminho").....	6
3.3. Consulta de Meta-informação (dclient -c "ID").....	7
3.4. Remoção de Meta-informação (dclient -d "ID").....	7
3.5. Pesquisa de Conteúdo.....	7
3.5.1. Contagem de Linhas (dclient -l "ID" "palavra-chave")	7
3.5.2. Pesquisa de Documentos por Palavra-Chave (Versão Sequencial - dclient -s "palavra-chave")	8
4. Otimizações	8
4.1. Pesquisa Concorrente (dclient -s "palavra-chave" "nr_processos").....	8
4.2. Persistência de Dados	9
4.3. Cache de Meta-informação	9
5. Conclusão	10

1. Introdução

Este relatório descreve o desenvolvimento de um serviço de indexação e pesquisa de documentos, realizado no âmbito da unidade curricular de Sistemas Operativos. O sistema implementa uma arquitetura cliente-servidor que permite a gestão de meta-informação de documentos e a pesquisa sobre o seu conteúdo.

Os principais objetivos incluem a aplicação de conceitos de gestão de processos, comunicação entre processos (IPC) utilizando pipes nomeados, persistência de dados, otimização de desempenho através de caching e pesquisa concorrente.

A seguir, são expostas as decisões tomadas pelo grupo, bem como o porquê das mesmas e as suas vantagens e eventuais desvantagens. Também é explicada a implementação de forma breve, havendo um melhor aprofundamento apenas nas partes em que o grupo considera ser mais relevantes para a compreensão do funcionamento do software desenvolvido.

2. Arquitetura do Sistema

- Modelo Cliente-Servidor:
 - O sistema adota um modelo cliente-servidor, onde um processo servidor (dserver) centraliza a gestão dos dados e o processamento dos pedidos, e múltiplos processos cliente (dclient) interagem com o servidor para realizar operações.
- Comunicação Interprocessos (IPC):
 - A comunicação entre o cliente e o servidor é realizada exclusivamente através de pipes nomeados (FIFOs). Esta escolha justifica-se pela sua capacidade de permitir a comunicação entre processos não relacionados (não descendentes diretos), sendo um mecanismo standard em sistemas POSIX como o Linux.
 - Pipe Principal do Servidor: O servidor cria um FIFO conhecido, definido por SERVER_PIPE (e.g., /tmp/server_pipe_so), no qual aguarda por pedidos de todos os clientes.
 - Pipes de Resposta do Cliente: Cada cliente, antes de enviar um pedido, cria o seu próprio FIFO para receber a resposta do servidor. O nome deste FIFO é único e construído utilizando o PID (Process ID) do cliente, conforme o formato CLIENT_PIPE_FORMAT (e.g., /tmp/client_pipe_so_<PID>). O PID do cliente é incluído no pedido enviado ao servidor.

- Estruturas de Dados para Comunicação:

- Os pedidos do cliente para o servidor são encapsulados na estrutura Request.

```
typedef struct {
    int operation;           // Código da operação a ser realizada (ver defines ADD_DOC, QUERY_DOC, etc.).
    Document doc;           // Estrutura `Document` contendo os dados do documento.
    // Usada nas operações ADD_DOC (para enviar novos dados),
    // QUERY_DOC (para enviar o ID na `doc.id`),
    // DELETE_DOC (para enviar o ID na `doc.id`),
    // COUNT_LINES (para enviar o ID na `doc.id`).
    char keyword[MAX_KEYWORD_SIZE]; // Palavra-chave para operações de pesquisa de conteúdo.
    // Usada em COUNT_LINES e SEARCH_DOCS.
    int client_pid;         // PID (Process ID) do processo cliente.
    // Essencial para o servidor saber para qual pipe de cliente deve enviar a resposta.
    int nr_processes;       // Número de processos a serem usados na pesquisa concorrente (SEARCH_DOCS).
    // Se não especificado ou  $\leq 1$ , a pesquisa é sequencial.
} Request;
```

- As respostas do servidor para o cliente são encapsuladas na estrutura Response.

```
typedef struct {
    int status;             // Código de estado da operação:
    // 0 indica sucesso.
    // Um valor negativo indica um erro específico (ex: -1 para "não encontrado").
    Document doc;           // Estrutura `Document` contendo os dados do documento retornado.
    // Preenchida na resposta a uma operação QUERY_DOC bem-sucedida.
    // Na resposta a ADD_DOC, `doc.id` contém o ID do novo documento.
    int count;              // Resultado da contagem de linhas.
    // Preenchido na resposta a uma operação COUNT_LINES bem-sucedida.
    int ids[MAX_RESULT_IDS]; // Array de IDs dos documentos encontrados numa pesquisa.
    // Preenchido na resposta a uma operação SEARCH_DOCS.
    int num_ids;            // Número de IDs válidos presentes no array `ids`.
    // Usado em conjunto com `ids` na resposta a SEARCH_DOCS.
} Response;
```

- Fluxo de Comunicação Típico:

1. O cliente cria o seu FIFO de resposta.
2. O cliente preenche uma estrutura Request e envia-a para o SERVER_PIPE.
3. O servidor lê o Request do SERVER_PIPE.
4. O servidor processa o pedido.
5. O servidor preenche uma estrutura Response e envia-a para o FIFO de resposta específico do cliente (identificado pelo client_pid no Request).
6. O cliente lê a Response do seu FIFO.
7. O cliente apresenta o resultado ao utilizador e remove o seu FIFO de resposta.

2.1 Servidor (dserver)

- Responsabilidades:
 - dserver é responsável por indexar meta-informação de documentos, processar consultas e pedidos de remoção, realizar pesquisas no conteúdo dos documentos, gerir a persistência dos dados e otimizar o acesso através de uma cache.
- Gestor de Pedidos:
 - servidor opera num ciclo principal, lendo sequencialmente os pedidos que chegam ao SERVER_PIPE.
 1. Processamento de Pedidos e Concorrência: Embora os pedidos sejam retirados do FIFO principal de forma sequencial, o servidor foi desenhado para minimizar o bloqueio de clientes. Para operações potencialmente longas, como a pesquisa por palavra-chave (-s), o servidor pode delegar o trabalho a múltiplos processos filhos, permitindo o processamento concorrente dessa pesquisa específica. No entanto, o ciclo principal do servidor que aceita novos pedidos permanece single-threaded, o que significa que um pedido muito demorado (mesmo que internamente paralelo) poderá atrasar o início do processamento do pedido seguinte.
- Arranque do Servidor:
 - Ao ser iniciado (./dserver document_folder cache_size), o servidor:
 1. Valida os argumentos da linha de comandos (pasta de documentos e tamanho da cache).
 2. Carrega a meta-informação persistida em disco.
 3. Inicializa a estrutura da cache com o tamanho especificado.
 4. Cria o SERVER_PIPE se este não existir.
 5. Regista handlers para sinais como SIGINT e SIGTERM para garantir um encerramento controlado (ver handle_signals no código).
- Encerramento do Servidor (dclient -f):
 - Quando o cliente envia o comando de encerramento (-f):
 1. O servidor recebe a operação SHUTDOWN.
 2. Realiza a persistência final dos dados da cache para o disco, se existirem modificações.
 3. Liberta os recursos alocados (e.g., memória da cache).
 4. Remove o SERVER_PIPE.
 5. Termina a sua execução.

2.2 Cliente (dclient)

- Funcionamento:
 - O dclient é uma aplicação de linha de comandos que executa uma única operação por invocação.
- Processamento de Argumentos:
 - Interpreta os argumentos fornecidos para construir a estrutura Request apropriada para a operação desejada (e.g., -a, -c, -d, -l, -s, -f).
- Comunicação:
 - Conforme descrito no fluxo de comunicação, cria o seu FIFO, envia o pedido, aguarda a resposta e processa-a.
- Saída e Limpeza:
 - Apresenta a informação relevante ao utilizador através do stdout e remove o seu FIFO privado após a conclusão da operação.

3. Implementação das Funcionalidades

3.1. Meta-informação de Documentos:

- A meta-informação de cada documento é armazenada numa estrutura Document.

```
typedef struct {  
    int id; // Identificador numérico único atribuído pelo servidor a cada documento.  
    char title[MAX_TITLE_SIZE]; // Título do documento.  
    char authors[MAX_AUTHORS_SIZE]; // Nome(s) do(s) autor(es) do documento.  
    char year[MAX_YEAR_SIZE]; // Ano de publicação do documento (como string).  
    char path[MAX_PATH_SIZE]; // Caminho relativo para o ficheiro físico do documento, a partir da pasta base configurada no servidor.  
} Document;
```

3.2. Indexação de Documentos (dclient -a "título" "autores" "ano" "caminho")

- O cliente envia os metadados para o servidor.
- O servidor valida o tamanho total dos argumentos (não excede 512 bytes) e os tamanhos individuais (e.g., título e autores até 200 bytes cada, caminho até 64 bytes, ano até 4 bytes).

- O servidor verifica a acessibilidade do ficheiro no caminho especificado (relativo à `document_folder`). O ficheiro deve existir e ser legível.
- Geração do Identificador Único: É atribuído um identificador numérico único (id) a cada novo documento. Este id é gerido pelo servidor através de um contador global (`next_id` em `dserver.c`) que é incrementado a cada nova adição e persistido juntamente com os dados.
- A meta-informação é adicionada à cache (e posteriormente ao disco).
- O servidor retorna o id atribuído ao cliente, que o exhibe.

3.3. Consulta de Meta-informação (`dclient -c "ID"`)

- O cliente envia o ID do documento a consultar.
- O servidor procura o documento (primeiro na cache, depois no disco, se necessário).
- Se encontrado, a meta-informação (título, autores, ano, caminho) é devolvida ao cliente e exibida. Caso contrário, é comunicada uma mensagem de erro.

3.4. Remoção de Meta-informação (`dclient -d "ID"`)

- O cliente envia o ID do documento a remover.
- O servidor remove a entrada de meta-informação da cache e do ficheiro de persistência.
- Importante: O ficheiro do documento em si não é apagado do sistema de ficheiros, apenas a sua indexação.
- O cliente informa o utilizador sobre o sucesso da operação.

3.5. Pesquisa de Conteúdo

3.5.1. Contagem de Linhas (`dclient -l "ID" "palavra-chave"`)

- O servidor localiza o documento pelo ID.
- Para contar as linhas que contêm a palavra-chave, o servidor utiliza um mecanismo de pipeline entre os comandos `grep` e `wc -l`. Isto é implementado da seguinte forma (conforme a função `count_lines_with_keyword` em `dserver.c`):
 1. São criados dois pipes anónimos.
 2. O servidor cria um primeiro processo filho (`fork`).
 - O `stdout` deste filho é redirecionado (`dup2`) para a extremidade de escrita do primeiro pipe.
 - Este filho executa (`execlp`) `grep palavra-chave /caminho/para/ficheiro_documento`.
 3. O servidor cria um segundo processo filho.
 - O `stdin` deste segundo filho é redirecionado para a extremidade de leitura do primeiro pipe.
 - O `stdout` deste segundo filho é redirecionado para a extremidade de escrita do segundo pipe.
 - Este filho executa `wc -l`.
 4. O processo servidor (pai) lê o resultado (a contagem de linhas) da extremidade de leitura do segundo pipe.
 5. O servidor aguarda (`waitpid`) a terminação de ambos os filhos.

3.5.2. Pesquisa de Documentos por Palavra-Chave (Versão Sequencial - `dclient -s "palavra-chave"`)

- O servidor itera por todos os documentos indexados (na cache e/ou disco).
- Para cada documento, verifica se contém a palavra-chave. Isto pode ser feito de forma similar à contagem de linhas, mas usando `grep -q palavra-chave /caminho/para/ficheiro`, que retorna um status de saída 0 se encontrar, sem produzir output. A função `search_documents_with_keyword_serial` em `dserver.c` implementa esta lógica.
- Os IDs dos documentos que contém a palavra-chave são acumulados e enviados ao cliente numa lista.

4. Otimizações

4.1. Pesquisa Concorrente (`dclient -s "palavra-chave" "nr_processos"`)

- Para acelerar a operação de pesquisa de documentos por palavra-chave, foi implementada uma versão concorrente que utiliza múltiplos processos.
- Implementação:
 1. O servidor obtém a lista de todos os documentos a serem pesquisados (combinando os da cache e os do disco, evitando duplicados).
 2. Se o número de processos (`nr_processos`) solicitado for maior que 1 e o número total de tarefas de pesquisa for significativo, a pesquisa paralela é ativada. Caso contrário (ou se `nr_processos <= 1`), recorre-se à pesquisa sequencial descrita em 3.5.2. (Ver lógica em `search_documents_with_keyword_parallel` em `dserver.c`).
 3. O conjunto total de documentos a pesquisar é dividido o mais equitativamente possível entre o `nr_processos` especificado.
 4. O servidor cria `nr_processos` processos filhos utilizando `fork`.
 5. Cada processo filho é responsável por pesquisar a palavra-chave no seu subconjunto de documentos. A pesquisa em cada ficheiro dentro do filho pode usar a mesma técnica de `count_lines_with_keyword` (para verificar se > 0) ou `grep -q`.
 6. Comunicação de Resultados Parciais: Cada processo filho escreve os IDs dos documentos que encontrou num ficheiro temporário único (e.g., `/tmp/search_results_child_<PID_PAI>_<INDICE_FILHO>.tmp`). Esta abordagem foi escolhida pela sua simplicidade na agregação e por evitar complexidades com múltiplos pipes para o pai.
 7. O processo pai (servidor) aguarda (`waitpid`) a terminação de todos os processos filhos.
 8. Após a terminação dos filhos, o pai lê os resultados de cada ficheiro temporário, agrega-os numa lista final de IDs (garantindo que não excede `MAX_RESULT_IDS`) e remove os ficheiros temporários.
 9. A lista final de IDs é enviada ao cliente.
- Justificação: A criação de processos distribuídos permite que a pesquisa em múltiplos ficheiros ocorra em paralelo, aproveitando sistemas multi-core e reduzindo o tempo total da operação para grandes volumes de dados. O uso de ficheiros temporários simplifica a agregação de resultados de múltiplos filhos assíncronos.

4.2. Persistência de Dados

- Para garantir a durabilidade da meta-informação dos documentos, mesmo após o encerramento do servidor, os dados são persistidos em disco.
- Implementação:
 - Ficheiro de Persistência: É utilizado um ficheiro binário, nomeadamente "database.bin" (conforme dserver.c).
 - Formato dos Dados:
 1. O next_id (próximo ID a ser atribuído) é guardado no início do ficheiro.
 2. Segue-se o número total de documentos (num_docs) atualmente guardados.
 3. Finalmente, as estruturas Document de cada documento são escritas sequencialmente.
 - Operações de Escrita (Save): Os dados são guardados no disco (save_documents em dserver.c):
 - Principalmente quando o servidor recebe o comando de encerramento (dclient -f) e a flag cache.modified indica que houve alterações.
 - Quando um documento é removido (remove_document), o ficheiro é reescrito para refletir a remoção.
 - Operações de Leitura (Load): Ao arrancar, o servidor (load_documents em dserver.c):
 1. Abre "database.bin".
 2. Lê o next_id e o total_docs_on_disk.
 3. Lê cada estrutura Document e carrega-a para a cache em memória, até ao limite da cache.
- Justificação: A persistência em ficheiro binário é eficiente em termos de espaço e velocidade de leitura/escrita comparativamente a formatos de texto para estruturas fixas.

4.3. Cache de Meta-informação

- Para acelerar o acesso à meta-informação frequentemente requisitada, o servidor mantém uma cache em memória.
- Implementação:
 - Tamanho da Cache: O tamanho da cache (N) é definido como um argumento na linha de comandos quando se inicia o dserver (./dserver document_folder cache_size). Este valor corresponde ao número máximo de entradas de meta-informação (Document) que a cache pode conter.
 - Estrutura da Cache: A cache é implementada como um array de ponteiros para estruturas Document (cache.docs em dserver.c).
 - Política de Cache:
 - Política de Adição: Novos documentos indexados são sempre adicionados à cache.
 - Política de Substituição: Quando um novo documento é adicionado e a cache está cheia (cache.num_docs >= cache.max_size), é aplicada uma política FCFS (First-Come, First-Served), também conhecida como FIFO (First-In, First-Out). O documento que está há mais tempo na cache (o que está no índice 0 do array, assumindo que novos elementos são adicionados no fim e os antigos "deslizam" ou são explicitamente geridos dessa forma) é removido para dar espaço ao novo. Esta política foi escolhida pela sua simplicidade de implementação. (Referenciar a função add_document em dserver.c que implementa esta lógica).

- Política de Leitura: Ao consultar um documento (-c), o servidor verifica primeiro a cache. Se o documento estiver presente (cache hit), é retornado diretamente. Se não (cache miss), e o documento for encontrado no disco, ele é carregado para a cache se houver espaço, ou se a política de substituição o permitir (neste caso, a adição à cache após um miss do disco parece acontecer se houver espaço, conforme find_document).
- Justificação: A cache reduz a necessidade de acessos ao disco, que são significativamente mais lentos que o acesso à memória, melhorando o tempo de resposta para consultas a documentos "quentes". A política FCFS é simples de implementar e gerir.

5. Conclusão

O projeto permitiu consolidar bem os conhecimentos lecionados pela cadeira de Sistemas operativos, nomeadamente no uso de FIFOs, sinais e gestão de processos.

A arquitetura cliente/servidor implementada demonstrou ser eficaz para comunicação interprocesso, com capacidade para escalar a múltiplos clientes. Apesar da simplicidade da aplicação, foram feitas escolhas importantes quanto à robustez, tratamento de erros e gestão de recursos.

A nosso ver o projeto atingiu os objetivos propostos, permitindo uma gestão eficaz de pedidos entre processos através de técnicas sólidas de IPC.